
PROPRIÉTÉS DU PSEUDO-ESTIMATEUR DU MAXIMUM DE VRAISEMBLANCE DANS UN MODÈLE DE RÉGRESSION

A PREPRINT

Raïssa Coulibaly

Chaire Co-operators en analyse des risques actuariels
Département de mathématiques
UQAM

21 octobre 2025

En considérant une distribution appartenant à la famille exponentielle linéaire de dispersion, nous montrons que l'estimateur du maximum de vraisemblance obtenu sous une mauvaise spécification du modèle de régression possède les mêmes propriétés que celui obtenu sous l'hypothèse d'une bonne spécification du modèle. En d'autres termes, nous démontrons que, même lorsque le modèle de régression est mal spécifié, l'estimateur du maximum de vraisemblance converge vers le vrai paramètre sous une condition précisée dans le présent travail. Nous établissons également que cet estimateur suit asymptotiquement une distribution normale dont la matrice de variance-covariance est identique à celle du cas bien spécifié.

1 Éléments contextuels

1.1 Définition

On appelle pseudo-estimateur du maximum de vraisemblance l'estimateur obtenu par la méthode de maximisation de la vraisemblance, mais dont la vraisemblance n'est pas construite à partir de la véritable distribution génératrice des données.

Par conséquent, on dit que le modèle de régression associé est mal spécifié, au sens discuté par [White \(1982\)](#).

Formellement, supposons que la variable réponse soit issue d'une distribution représentée par sa fonction de densité ou de probabilité g , généralement inconnue, mais dépendant d'un paramètre β , objet de l'inférence statistique.

On suppose alors une autre distribution pour la variable réponse, représentée par sa fonction de densité ou de probabilité f , qui dépend elle aussi du paramètre β et qui, elle, est connue.

Comme on ne dispose d'aucune information sur la fonction g , on admet que $f \neq g$.

Ainsi, la fonction de vraisemblance construite à l'aide de la fonction f est appelée pseudo-vraisemblance, et l'estimateur $\hat{\beta}$ de β , issu de la maximisation de cette dernière, est appelé pseudo-estimateur du maximum de vraisemblance de β .

1.2 Objectif du papier

L'objectif de ce travail est de présenter les propriétés du pseudo-estimateur du maximum de vraisemblance, telles que discutées par [White \(1982\)](#), et d'en proposer certaines justifications dans le cas où la fonction f appartient à la famille exponentielle linéaire de dispersion, dont la définition est donnée ci-après.

1.3 Famille exponentielle linéaire de dispersion

Notons qu'on confondra souvent, par abus de langage, la distribution d'une variable aléatoire avec sa fonction de densité ou de probabilité. Ainsi, on dit que la fonction f appartient à la famille exponentielle linéaire de dispersion si elle s'écrit sous la forme :

$$f(y) = c(y, \phi) \exp \left\{ \frac{y (a')^{-1}(\mu) - a((a')^{-1}(\mu))}{\frac{\phi}{w}} \right\}, \quad y \in \mathbf{R},$$

où :

- μ est le paramètre de moyenne, défini par :

$$\mu = \int_{\mathbf{R}} y f(y) dy;$$

- $a(\cdot)$ est la fonction des cumulants ;
- ϕ est le paramètre de dispersion ;
- w est le paramètre de poids ;
- $c(y, \phi)$ est la constante de normalisation, indépendante de μ .

1.4 Hypothèses et notations

- **Hypothèses sur la vraie distribution**

Nous notons le vrai paramètre par β^t et supposons que la vraie moyenne, notée μ^t , est liée au vecteur de covariables, $\mathbf{x}$, de la manière suivante :

$$\mu^t = \int_{\mathbf{R}} y g(y) dy = h^t(\mathbf{x}^\top \beta^t),$$

où h^t est une fonction inconnue.

- **Hypothèses sur la distribution de la variable réponse**

On suppose que la distribution de la variable réponse appartient à la famille exponentielle linéaire de dispersion, dont la densité (ou loi de probabilité) est représentée par la fonction f . On suppose également que le paramètre de moyenne μ s'exprime comme :

$$\mu = h^{-1}(\mathbf{x}^\top \beta),$$

où h est la fonction de lien utilisée dans la théorie des modèles linéaires généralisés (GLM) ([Nelder and Wedderburn, 1972](#)), $\mathbf{x}$ est un vecteur de covariables et β un vecteur de paramètres réels.

- **Divergence de Kullback–Leibler**

On suppose que la distance entre les deux distributions f et g peut être évaluée à l'aide de la divergence de Kullback–Leibler, définie par :

$$KL(\beta) = \int_{\mathbf{R}} \log \left(\frac{g(y)}{f(y)} \right) g(y) dy = \int_{\mathbf{R}} \log(g(y)) g(y) dy - \int_{\mathbf{R}} \log(f(y)) g(y) dy.$$

On note également par β^* la valeur du paramètre β qui minimise la divergence de Kullback–Leibler entre les fonctions f et g .

2 Consistance du pseudo-estimateur du maximum de vraisemblance

Nous notons le pseudo-estimateur du maximum de vraisemblance de β^t par $\hat{\beta}$. Il convient de noter que ce pseudo-estimateur s'obtient de la même manière que l'estimateur classique du maximum de vraisemblance dans la théorie des GLM, en utilisant la fonction f .

Théorème 1. Si $h^t = h^{-1}$, autrement dit si le paramètre de moyenne de la vraie distribution g et celui de la distribution de la variable réponse f sont liés aux covariables de la même manière, alors $\hat{\beta}$ est un estimateur **consistant** de β^t . Mathématiquement, cela s'écrit :

$$\lim_{n \rightarrow +\infty} \Pr\left(|\hat{\beta} - \beta^t| > \epsilon\right) = 0, \quad \forall \epsilon > 0.$$

Démonstration. Selon [White \(1982\)](#), le pseudo-estimateur $\hat{\beta}$ converge en probabilité vers β^* , c'est-à-dire que :

$$\lim_{n \rightarrow +\infty} \Pr\left(|\hat{\beta} - \beta^*| > \epsilon\right) = 0, \quad \forall \epsilon > 0.$$

La démonstration consiste donc à montrer que $\beta^* = \beta^t$.

On suppose que les paramètres de moyenne des deux distributions sont liés de la même manière aux covariables, c'est-à-dire que :

$$\mu^t = h^{-1}(\mathbf{x}^\top \beta^t), \quad \mu = h^{-1}(\mathbf{x}^\top \beta).$$

On peut aussi noter que β^* est la valeur de β qui maximise la fonction intégrale suivante :

$$\int_{\mathbb{R}} \log(f(y)) g(y) dy.$$

Or, comme f appartient à la famille exponentielle linéaire de dispersion, on a :

$$\begin{aligned} \int_{\mathbb{R}} \log(f(y)) g(y) dy &= \int_{\mathbb{R}} \frac{w}{\phi} \left[y (a')^{-1}(\mu) - a\left((a')^{-1}(\mu)\right) \right] g(y) dy + \int_{\mathbb{R}} \log(c(y, \phi)) g(y) dy \\ &= \frac{w}{\phi} \left[\mu^t (a')^{-1}(\mu) - a\left((a')^{-1}(\mu)\right) \right] + \int_{\mathbb{R}} \log(c(y, \phi)) g(y) dy \\ &\propto \mu^t (a')^{-1}(\mu) - a\left((a')^{-1}(\mu)\right). \end{aligned}$$

En posant

$$K(\beta) = \mu^t (a')^{-1}(\mu) - a\left((a')^{-1}(\mu)\right),$$

on remarque que β^* est la valeur de β qui maximise K . Autrement dit, si $\nabla K(\beta)$ désigne le gradient associé à K , alors :

$$\nabla K(\beta^*) = \mathbf{0}.$$

Le calcul du gradient donne :

$$\nabla K(\beta) = \frac{\mu^t - \mu}{a''\left((a')^{-1}(\mu)\right)} \times \frac{1}{h'(\mu)} \times \mathbf{x}.$$

Puisque les moyennes μ^t et μ sont définies par des fonctions de lien identiques, il suffit que $\beta = \beta^t$ pour que le gradient soit nul. Ainsi, on a bien :

$$\beta^t = \beta^*,$$

ce qui achève la démonstration. □

3 Distribution asymptotique du pseudo-estimateur du maximum de vraisemblance

Comme conséquence immédiate du Théorème 1, on peut noter que le pseudo-estimateur du maximum de vraisemblance $\hat{\beta}$ converge également en loi vers β^t , tant que les deux moyennes sont liées par la même fonction de lien h .

D'après [White \(1982\)](#), la distribution asymptotique de $\hat{\beta}$ est donnée par :

$$\hat{\beta} \sim \mathcal{N}(\beta^t, A^{-1} B A^{-1}),$$

où

$$A = -I(\beta) \quad \text{et} \quad B = E[\nabla(\beta) \nabla(\beta)^\top],$$

avec $I(\beta)$ la matrice d'information de Fisher et $\nabla(\beta)$ le gradient de la fonction log-vraisemblance construite à partir de la fonction f .

Avant d'énoncer le deuxième théorème du papier, nous allons d'abord montrer comment obtenir la matrice d'information de Fisher ainsi que le gradient de la fonction log-vraisemblance.

3.1 Calcul du gradient et de la matrice d'information de Fisher

Nous supposons n v.a indépendantes $Y_1, \dots, Y_n$ et n vecteurs de covariables $\mathbf{X}_1, \dots, \mathbf{X}_n$. On suppose que conditionnellement à $\mathbf{X}_i$, la distribution commune des Y_i est donnée par la fonction f qui appartient à la famille exponentielle linéaire de dispersion telle que mentionné plus haut. Nous supposons également le paramètre de moyenne y afferant est donné par

$$\mu_i = h^{-1}(\mathbf{X}_i^\top \beta),$$

ou la fonction de lien h est la même que dans la vraie distribution génératrice des données. Nous notons aussi par y_i , la valeur observée de Y_i et construisons la fonction log-vraisemblance comme-suit :

$$\ell(\beta) = \sum_{i=1}^n \log(f(y_i)) = \sum_{i=1}^n \frac{w_i}{\phi} \left[y_i (a')^{-1}(\mu_i) - a((a')^{-1}(\mu_i)) \right] + \sum_{i=1}^n \log(c(y_i, \phi)),$$

avec w_i , le poids de l'observation i et le paramètre ϕ de dispersion ϕ est supposé constant pour toutes les observations.

Pour faciliter la compréhension du gradient, on adopte les notations et hypothèses suivantes :

- $\mathbf{X}_i = (X_{i,0}, \dots, X_{i,q})^\top : X_{i,0} = 1, \quad X_{i,j} \in \mathbf{R}, j = 1, \dots, q, \quad q \geq 1.$
- $\beta = (\beta_0, \dots, \beta_q)^\top, \beta_j \in \mathbf{R}, \quad j = 0, \dots, q.$

3.1.1 Gradient

On calcule le gradient comme-suit :

$$\nabla(\beta) = \frac{\partial \ell(\beta)}{\partial \beta} = \mathbf{X}^\top \mathbf{D} \mathbf{R},$$

avec :

- Les dérivées partielles qui s'obtiennent comme-suit :

$$\frac{\partial \ell(\beta)}{\partial \beta_j} = \sum_{i=1}^n \frac{w_i}{\phi} \frac{y_i - \mu_i}{h'(\mu_i) a''((a')^{-1}(\mu_i))} x_{i,j}, \quad \text{pour tout } j = 0, \dots, q.$$

- La matrice $\mathbf{X}$, appelée la matrice design, qui est :

$$\mathbf{X} = \begin{pmatrix} x_{1,0} & x_{1,1} & \cdots & x_{1,q} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,0} & x_{n,1} & \cdots & x_{n,q} \end{pmatrix}.$$

- La matrice $\mathbf{D}$ et le vecteur $\mathbf{R}$ sont donnés par

$$\mathbf{D} = \text{diag} \left(\frac{w_i}{(h'(\mu_i))^2 a''((a')^{-1}(\mu_i))} \right)_{i=1, \dots, n}, \quad \mathbf{R} = \begin{pmatrix} h'(\mu_1)(y_1 - \mu_1) \\ \vdots \\ h'(\mu_n)(y_n - \mu_n) \end{pmatrix}.$$

3.1.2 Matrice d'information de Fisher

La matrice d'information de Fisher est définie par :

$$I(\beta) = -\mathbb{E} \left[\frac{\partial \nabla(\beta)}{\partial \beta^\top} \right] = \frac{1}{\phi} \mathbf{X}^\top \mathbf{D} \mathbf{X},$$

où $\frac{\partial \nabla(\beta)}{\partial \beta^\top}$ est appelée la matrice hessienne et est donnée par :

$$\frac{\partial \nabla(\beta)}{\partial \beta^\top} = \frac{\partial^2 \ell(\beta)}{\partial \beta \partial \beta^\top} = \begin{pmatrix} \frac{\partial^2 \ell(\beta)}{\partial \beta_0^2} & \cdots & \frac{\partial^2 \ell(\beta)}{\partial \beta_0 \partial \beta_q} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 \ell(\beta)}{\partial \beta_q \partial \beta_0} & \cdots & \frac{\partial^2 \ell(\beta)}{\partial \beta_q^2} \end{pmatrix}.$$

Les dérivées partielles et leur espérance mathématique s'obtiennent comme-suit

$$\begin{aligned} \frac{\partial^2 \ell(\beta)}{\partial \beta_j \partial \beta_k} &= \sum_{i=1}^n \frac{w_i}{\phi} \left(\frac{-h'(\mu_i) a''((a')^{-1}(\mu_i)) - (y_i - \mu_i) \left[h''(\mu_i) a''((a')^{-1}(\mu_i)) + h'(\mu_i) \frac{a''''((a')^{-1}(\mu_i))}{a'''((a')^{-1}(\mu_i))} \right]}{(h'(\mu_i) a''((a')^{-1}(\mu_i)))^2} \right) x_{i,j} \times \frac{1}{h'(\mu_i)} \times x_{i,k}. \\ \mathbb{E} \left[\frac{\partial^2 \ell(\beta)}{\partial \beta_j \partial \beta_k} \right] &= -\frac{1}{\phi} \sum_{i=1}^n \frac{w_i}{(h'(\mu_i))^2 a''((a')^{-1}(\mu_i))} x_{i,j} x_{i,k}. \end{aligned}$$

3.2 Distribution asymptotique

Théorème 2. Si $h^t = h^{-1}$, autrement dit si le paramètre de moyenne de la vraie distribution g et celui de la distribution de la variable réponse f sont liés aux covariables de la même manière, alors la distribution asymptotique de $\hat{\beta}$ est donnée par :

$$\hat{\beta} \sim \mathcal{N}(\beta^t, \phi (\mathbf{X}^\top \mathbf{D} \mathbf{X})^{-1}).$$

Démonstration. Il suffit de montrer que la matrice de variance-covariance de $\hat{\beta}$ est l'inverse de la matrice d'information de Fisher $I(\beta)$, c'est-à-dire :

$$A^{-1} B A^{-1} = \phi (\mathbf{X}^\top \mathbf{D} \mathbf{X})^{-1}.$$

Pour prouver cela, on montre que $B = -A = -I(\beta)$.

En effet, on a :

$$B = \mathbb{E} \left[\begin{pmatrix} \sum_{i=1}^n \frac{w_i}{\phi} \frac{Y_i - \mu_i}{h'(\mu_i) a''((a')^{-1}(\mu_i))} x_{i,0} \\ \vdots \\ \sum_{i=1}^n \frac{w_i}{\phi} \frac{Y_i - \mu_i}{h'(\mu_i) a''((a')^{-1}(\mu_i))} x_{i,q} \end{pmatrix} \times \begin{pmatrix} \sum_{i=1}^n \frac{w_i}{\phi} \frac{Y_i - \mu_i}{h'(\mu_i) a''((a')^{-1}(\mu_i))} x_{i,0} \\ \vdots \\ \sum_{i=1}^n \frac{w_i}{\phi} \frac{Y_i - \mu_i}{h'(\mu_i) a''((a')^{-1}(\mu_i))} x_{i,q} \end{pmatrix}^\top \right].$$

Sous forme matricielle, on obtient alors :

$$B = \frac{1}{\phi^2} \left(\mathbb{E} \left[\sum_{i=1}^n w_i^2 \frac{(Y_i - \mu_i)^2}{(h'(\mu_i) a''((a')^{-1}(\mu_i)))^2} x_{i,j} x_{i,k} \right] \right)_{j,k=0,\dots,q}.$$

Or, nous savons que la variance d'une distribution appartenant à la famille exponentielle linéaire de dispersion est donnée par :

$$E[(Y_i - \mu_i)^2] = \frac{\phi}{w_i} a''((a')^{-1}(\mu_i)) .$$

En remplaçant cette dernière expression dans B , on obtient :

$$B = \frac{1}{\phi^2} \left(\sum_{i=1}^n w_i^2 \frac{\frac{\phi}{w_i} a''((a')^{-1}(\mu_i))}{(h'(\mu_i) a''((a')^{-1}(\mu_i)))^2} x_{i,j} x_{i,k} \right)_{j,k=0,\dots,q} .$$

Après simplification, on obtient à nouveau :

$$B = \frac{1}{\phi} \left(\sum_{i=1}^n \frac{w_i}{(h'(\mu_i))^2 a''((a')^{-1}(\mu_i))} x_{i,j} x_{i,k} \right)_{j,k=0,\dots,q} = -A.$$

Ce qui met fin à la démonstration. □

Références

- Nelder, J. A. and Wedderburn, R. W. (1972). Generalized linear models. *Journal of the Royal Statistical Society Series A : Statistics in Society*, 135(3) :370–384.
- White, H. (1982). Maximum likelihood estimation of misspecified models. *Econometrica : Journal of the econometric society*, pages 1–25.