
ÉVALUATION DE L'ADÉQUATION ET CHOIX DU MODÈLE EN RÉGRESSION LOGISTIQUE

A PREPRINT

Raïssa Coulibaly

Chaire Co-operators en analyse des risques actuariels
Département de mathématiques
UQAM

28 octobre 2025

Ce document complète le chapitre 4 consacré au modèle de régression logistique. L'objectif est de présenter un outil permettant d'évaluer la qualité d'ajustement d'un modèle de régression logistique, ainsi que de servir de critère de sélection de modèles. Cet outil est la courbe ROC (Receiver Operating Characteristic). Aucun test statistique associé à cette courbe n'est abordé ici ; seule une analyse graphique est proposée. Il convient également de noter que cet outil est valable de manière générale pour l'évaluation de la qualité d'ajustement et la sélection de modèles dans un modèle de régression binaire, c'est-à-dire un modèle de régression où la variable à expliquer ne prend que deux modalités..

1 Contexte

Dans un modèle de régression linéaire, nous avons vu que le test de Fisher permet de vérifier à la fois la linéarité et la qualité d'ajustement du modèle. Cependant, le résultat de ce test n'est valable que si les erreurs suivent une distribution normale. Ainsi, pour évaluer cette hypothèse de normalité, nous avons recours à une analyse graphique à l'aide du QQ-plot.

Dans le modèle de régression logistique, il est également possible de tester la significativité globale des paramètres du modèle. Toutefois, la validité de ce test n'est qu'asymptotique, c'est-à-dire qu'elle ne s'applique de manière fiable que lorsque la taille de l'échantillon est suffisamment grande.

C'est pourquoi il est préférable d'utiliser un outil plus adapté aux données binaires, tel que la courbe ROC, pour évaluer l'ajustement du modèle de régression logistique. Cette courbe peut également servir de critère de sélection de modèles.

En résumé, l'utilisation de la courbe ROC dans la régression logistique est analogue à celle du QQ-plot dans la régression linéaire, car elle permet une évaluation visuelle de la qualité d'ajustement du modèle. Nous définissons ci-après les éléments nécessaires à la construction de la courbe ROC, en nous basant sur les références [De Jong and Heller \(2008\)](#) et [Nakas et al. \(2023\)](#).

2 Sensibilité et spécificité

Nous modélisons la survenance d'un événement à l'aide d'un modèle de régression logistique. La variable à expliquer prend donc deux modalités, que nous définissons à partir de la variable aléatoire suivante :

$$Y = \begin{cases} 1 & \text{si l'événement a lieu,} \\ 0 & \text{si l'événement n'a pas lieu.} \end{cases}$$

Nous adoptons les termes **succès** pour désigner le cas où l'événement a lieu, et **échec** lorsque l'événement ne se produit pas. Nous avons alors les définitions suivantes :

- **Sensibilité** : proportion de succès correctement prédits parmi les succès observés.
- **Spécificité** : proportion d'échecs correctement prédits parmi les échecs observés.

2.1 Formalisation mathématique

Nous considérons n variables aléatoires indépendantes telles que Y_i est définie comme la variable Y . Nous notons par y_i la valeur observée de Y_i et par $\hat{\mu}_i$ la valeur prédite de Y_i à partir d'un modèle de régression logistique.

Il faut noter que, bien que Y_i soit une variable discrète, sa prédiction (ou estimation) $\hat{\mu}_i$ est une variable continue, car :

$$0 < \hat{\mu}_i < 1.$$

L'idée du calcul de la **sensibilité** et de la **spécificité** est de vérifier si l'approximation de Y_i par une variable continue est adéquate ou non. Pour cela, le calcul de la sensibilité et de la spécificité commence par la **discrétisation** de la moyenne estimée (ou prédite) $\hat{\mu}_i$. Plus spécifiquement, on construit une nouvelle variable $\hat{y}_i$ telle que :

$$\hat{y}_i = \begin{cases} 1 & \text{si } \hat{\mu}_i > c, \\ 0 & \text{si } \hat{\mu}_i \leq c, \end{cases}$$

où c est une constante choisie par l'utilisateur.

Ainsi, on définit :

- la **sensibilité** $Sen(c)$ pour la constante c comme :

$$Sen(c) = \frac{\sum_{i=1}^n \hat{y}_i}{\sum_{i=1}^n y_i},$$

- la **spécificité** $Sep(c)$ pour la constante c comme :

$$Sep(c) = \frac{n - \sum_{i=1}^n \hat{y}_i}{n - \sum_{i=1}^n y_i}.$$

2.2 Interprétations

L'idéal est d'avoir un modèle pour lequel la **spécificité** et la **sensibilité** valent toutes deux 1, ce qui indiquerait que le modèle est parfaitement adéquat. Cependant, on peut également accepter qu'un modèle soit considéré comme adéquat lorsque ces deux grandeurs sont proches de 1.

Ces quantités peuvent aussi être utilisées pour **sélectionner un modèle**. Ainsi, parmi plusieurs modèles candidats, le meilleur est celui pour lequel la sensibilité et la spécificité sont les plus proches de 1, pour une valeur donnée de c , souvent appelée **seuil** (ou *threshold* en anglais).

Le plus souvent, la sensibilité et la spécificité sont calculées à partir d'un **tableau de classification**, appelé également en anglais *confusion matrix*. Ce tableau se présente comme suit :

Valeurs observées	Valeurs prédites		Total
	$\hat{y}_i = 1$	$\hat{y}_i = 0$	
$y_i = 1$	$\sum_{i=1}^n \hat{y}_i$	$\sum_{i=1}^n y_i - \sum_{i=1}^n \hat{y}_i$	$\sum_{i=1}^n y_i$
$y_i = 0$	$\sum_{i=1}^n \hat{y}_i - \sum_{i=1}^n y_i$	$n - \sum_{i=1}^n \hat{y}_i$	$n - \sum_{i=1}^n y_i$
Total	$2 \sum_{i=1}^n \hat{y}_i - \sum_{i=1}^n y_i$	$n + \sum_{i=1}^n y_i - 2 \sum_{i=1}^n \hat{y}_i$	n

TABLE 1 – Tableau de classification pour un seuil c

— **Exemple :** Cet exemple est tiré de la page 108 du livre [De Jong and Heller \(2008\)](#).

Valeurs observées	Valeurs prédites		Total
	$\hat{y}_i = 1$	$\hat{y}_i = 0$	
$y_i = 1$	884	3740	4624
$y_i = 0$	9036	54196	63232
Total	9920	57936	67856

TABLE 2 – Tableau de classification pour un seuil $c = 0,08$

Les valeurs de la sensibilité et de la spécificité pour ce seuil sont :

$$Sen(0,08) = \frac{884}{4624} = 0,19, \quad Sep(0,08) = \frac{54196}{63232} = 0,85.$$

On observe que ce modèle présente une grande proportion d'échecs correctement prédits (spécificité élevée) mais une faible proportion de succès correctement prédits (sensibilité faible).

2.3 Remarques

On observe que la sensibilité décroît lorsque la constante c augmente, tandis que la spécificité croît avec ce même seuil. En effet, si la valeur du seuil c augmente, plusieurs succès réels sont prédits comme des échecs, ce qui diminue le nombre de succès correctement prédits. À l'inverse, plus le seuil est élevé, plus les échecs réels sont correctement identifiés, ce qui augmente la spécificité.

Les cas extrêmes sont également à considérer :

- Lorsque $c \rightarrow +\infty$, toutes les observations sont prédites comme des échecs ; la sensibilité vaut alors 0, tandis que la spécificité vaut 1.
- Lorsque $c \rightarrow 0$, toutes les observations sont prédites comme des succès ; la sensibilité vaut alors 1, tandis que la spécificité vaut 0.

On remarque donc qu'un **compromis** est nécessaire pour le choix de c , afin d'obtenir un modèle dont la sensibilité et la spécificité peuvent être considérées comme acceptables pour juger de la qualité d'ajustement d'un modèle logistique. C'est précisément ce compromis que met en évidence la courbe ROC, présentée dans la section suivante.

3 Courbe ROC

L'idée est de calculer les prédictions $\hat{\mu}_1, \dots, \hat{\mu}_n$ issues du modèle de régression logistique. Ensuite, on ordonne ces valeurs de la plus petite à la plus grande dans l'ensemble défini comme suit :

$$\mathbf{P} = \{\hat{\mu}_{(1)}, \dots, \hat{\mu}_{(n)}\},$$

où $\hat{\mu}_{(i)}$ désigne la i -ème plus petite prédiction parmi l'échantillon des valeurs estimées.

Pour chaque valeur de $c \in \mathbf{P}$, on calcule alors la variable $\hat{y}$, la spécificité et la sensibilité correspondantes. En résumé, on obtient ainsi n couples de valeurs $(Sen(c), Sep(c))$.

La courbe ROC est obtenue en représentant, pour chaque valeur de $c \in \mathbf{P}$, le couple :

$$(Sen(c), 1 - Sep(c)).$$

La figure 1 est une illustration de la courbe ROC. Chaque point de la courbe bleue représente une valeur spécifique du seuil c .




FIGURE 1 – Illustration de la courbe ROC

3.1 Adéquation du modèle

Une bonne courbe ROC est celle qui se rapproche le plus possible du coin supérieur gauche de la figure 2. Pour une telle courbe, la sensibilité et la spécificité sont toutes deux élevées.

Dans l'illustration, nous pouvons dire que le modèle correspondant à la courbe bleue est adéquat, car elle se situe bien au-dessus de la diagonale. En effet, si la courbe ROC coïncidait avec la diagonale (représentée par la ligne rouge), cela signifierait que le modèle logistique prédit aléatoirement les succès et les échecs. Ainsi, l'objectif est d'obtenir une courbe la plus éloignée possible vers le haut par rapport à cette diagonale.

Pour quantifier cette performance, on calcule souvent **l'aire sous la courbe ROC (AUC)**. Ce calcul peut être effectué manuellement à l'aide de méthodes numériques d'approximation d'aires, ou à l'aide d'une fonction de R. C'est cette dernière approche que nous utilisons dans ce cours. Une application concrète est proposée dans les travaux pratiques qui accompagnent ce chapitre.




FIGURE 2 – Illustration de la courbe ROC

Dans l'illustration de la figure 2, l'aire du modèle est de $AUC = 0,63$, ce qui est supérieur à celle de la diagonale ($AUC = 0,50$). Cela confirme la bonne qualité d'ajustement du modèle représenté par la ligne bleue.

3.2 Sélection de modèle

Pour utiliser la courbe ROC dans un but de sélection de modèle, on trace les courbes ROC des différents modèles candidats. Ensuite, on choisit comme meilleur modèle celui dont la courbe ROC se situe au-dessus de toutes les autres. En d'autres termes, il s'agit du modèle pour lequel l'aire sous la courbe (AUC) est la plus élevée.

Dans l'illustration de la figure 3, le meilleur modèle est celui dont la courbe ROC est en **bleu**, puisqu'il présente la valeur d'AUC la plus élevée parmi les trois modèles comparés.




FIGURE 3 – Illustration d'une sélection de modèle avec la courbe ROC

Remarques : L'utilisation de la courbe ROC n'est pas toujours indispensable pour la sélection de modèle. En effet, pour un seuil c donné, si la sensibilité et la spécificité d'un modèle sont toutes deux plus élevées que celles des autres modèles, alors ce modèle peut être considéré comme le meilleur pour ce seuil c choisi par l'utilisateur.

Références

- De Jong, P. and Heller, G. Z. (2008). *Generalized linear models for insurance data*. Cambridge University Press.
- Nakas, C. T., Bantis, L. E., and Gatsonis, C. A. (2023). *ROC analysis for classification and prediction in practice*. Chapman and Hall/CRC.